评分轮盘：LLM 评审框架中的自我不一致性

原题：Rating Roulette: Self-Inconsistency in LLM-As-A-Judge Frameworks

作者：Rajarshi Haldar、Julia Hockenmaier。

单位：伊利诺伊大学厄巴纳—香槟分校。

出处：Findings of the Association for Computational Linguistics: EMNLP 2025，第 24986–25004 页，2025 年 11 月，中国苏州。DOI：10.18653/v1/2025.findings-emnlp.1361。

论文主页 | 原文 PDF

译文说明。依据上述 19 页会议论文翻译。包含摘要、全部正文、局限性、致谢、附录 A–E、全部 7 张表和 12 幅图的图注；提示词及图中的文字示例译出，统计图以原 PDF 页码链接保留，不凭图形估算未报告数值。参考文献列出中文题名与原文检索信息，完整作者名单和出版信息见原文。为便于阅读，附录 A 中的提示词集中排列，参考文献放在附录之后。标为“译者注”的内容不是原论文。本文为中文翻译改编，未经作者审定。原论文为 ACL 版权材料，根据 ACL 的版权说明，适用 CC BY 4.0 许可。

术语对照

原文	本文译法	大白话理解
LLM-as-a-judge	以 LLM 为评审 / LLM 评审	让大语言模型给别的回答打分或判优
self-reliability / intra-rater reliability	自我信度 / 评审者内信度	同一个评审反复评同一材料，结果稳不稳
inter-rater reliability	评审者间信度	不同评审评价同一材料，结果是否一致
agreement	一致性 / 一致程度	评分或标签相符到什么程度
consistency（摘要质量维度）	事实一致性	摘要与原文的事实是否相符
coherence	连贯性	结构和逻辑是否连贯
fluency	流畅性	语法、措辞等是否通顺
relevance	相关性	是否抓住重点、避免无关与冗余信息
balanced accuracy	平衡准确率	二分类中灵敏度与特异度的平均值
chance agreement	偶然一致	即使随机给标签，也可能碰巧相同

译者注：“评分稳定”“符合人工判断”和“判断正确”是不同概念。本文主要研究前两者之间的关系，不能把其中任何一个直接等同于客观正确性。原文对 $\alpha \approx 0.8$ 等阈值的判断按原文保留，不将其扩大为所有任务通用的硬标准。

摘要

随着自然语言生成（NLG）的广泛应用，如何恰当地评估生成结果变得相当困难。近来，使用大语言模型（LLM）评估生成文本的做法越来越受关注，因为与传统的 n 元语法指标或基于嵌入的指标相比，它们通常更符合人类偏好。

我们的实验表明，LLM 评审在不同运行中给出的分数，具有较低的评审者内信度。这种波动使评分前后不一致，最严重时几乎随意，也让我们难以衡量其判断到底有多好。

我们在不同 NLG 任务和基准上量化这种不一致性，并考察：遵循适当准则、审慎使用 LLM 评审，是否仍能使其发挥作用。

1 引言

自然语言生成越来越多地用于自动新闻写作、客服聊天机器人、语言翻译和内容摘要等应用。要提高用户信任和系统效用，就必须恰当地评估生成质量，并衡量其与人类偏好的一致程度。BLEU（Papineni 等，2002）和 BERTScore（Zhang 等，2020）等传统自动指标，在翻译这类可以提供多个参考答案的任务上表现良好，但在摘要或一般聊天机器人场景等更开放的任务中却难以奏效。

为了在这些场景中自动评估 LLM，“以 LLM 为评审”（Li 等，2024；Gu 等，2025）作为人工评估的自动化、可扩展替代方案而兴起。常见做法是通过提示词让 LLM 评价自然语言生成结果，再将所得评分与人类评审给出的评分比较，把后者当作金标准。对于类别标签，这种比较通常计算精确匹配；对于数值或有序量表，则通常计算相关性（Liu 等，2023；Thakur 等，2025a）。

然而，这些研究经常缺少一项衡量：LLM 和人类评审各自的自我信度，也就是评审者内信度。我们将自我信度定义为：在设置相同的条件下，某位评审多次评价时与自身保持一致的程度。对 LLM 而言，相同设置指相同提示词和超参数。

现有基准的人工标注中，则完全缺少自我信度数据。有些基准提供多个不同人类评审的标注，但这只能告诉我们评审者间信度；而且该信度也经常低于通常认可的一致性阈值（Falke 等，2019；Fabbri 等，2021；Pagnoni 等，2021）。

此外，LLM 与人类评审之间的一致性，通常用相关性和准确率等指标计算，而不是采用 Krippendorff’s Alpha 这类专门衡量一致性的指标。这经常会高估一致程度，因为前述指标没有考虑偶然一致（Thakur 等，2025b）。

NLG 可以在机器翻译、对话生成、摘要等多种任务上，用不同指标评估。在实验中，我们先研究最简单的摘要评估：为 SummaC 基准（Laban 等，2022）中的摘要赋予二分类标签。接着，我们研究更复杂的情形，在 1–5 分的李克特量表上，对摘要的连贯性、事实一致性、流畅性和相关性等维度评分。SummEval 基准可用于这一目的。最后，我们研究另一种 NLG 任务：让 LLM 评审为 MT-Bench（Zheng 等，2023）中两个竞争模型的多轮对话判优。

本文为理解 LLM 生成评分在 NLG 评估中的可靠性，作出以下贡献。第一，我们表明：即便提示词相同，LLM 多次运行给出的评分仍然一致性较低。第二，关闭采样虽然可以让 LLM 始终输出同一评分，却会损害以“与人工判断一致程度”衡量的性能。第三，我们发现，这种现象在多种 NLG 任务和基准中持续存在，说明它是一个需要解决的普遍问题。最后，我们提出开展更稳健 NLG 评估的若干建议。

2 背景

自然语言生成的评估。NLG 评估的金标准一直依赖以人为中心的评估，即由人类评审评价生成文本。但这种做法耗时、昂贵，也容易不可靠和产生偏差（Thomson 等，2024）。现有研究报告的标注者间一致性往往较低，或者干脆不报告。例如，Celikyilmaz 等（2021）发现，在调查的 135 篇论文中，只有 18% 提供一致性分析。此外，采用众包评估的 Chatbot Arena（Chiang 等，2024）等排行榜，也存在使竞争不公平的差异（Singh 等，2025）。

与人工评估相比，BLEU（Papineni 等，2002）、ROUGE（Lin，2004）、METEOR（Banerjee 与 Lavie，2005）等自动指标，以及 BERTScore（Zhang 等，2020）、BLEURT（Sellam 等，2020）等基于模型的指标，更快、主观性更低，也更易扩展。但它们经常不能完整反映人类对质量的理解，尤其是在主观任务上。

以 LLM 为评审。大语言模型可以通过给生成结果打分、排序或赋予标签来充当评审。近期综述讨论了这一范式（Li 等，2024；Gu 等，2025）。LLM 评审已应用于 20 种 NLP 任务（Bavaresco 等，2024），也被整合进 AI 辅助人工评估（Ashktorab 等，2024）。特别是在 NLG 任务上，配合思维链提示词的 GPT-4，比传统自动指标更符合人类判断（Liu 等，2023；OpenAI 等，2024；Wei 等，2022）。

通常，研究通过相关性（Liu 等，2023；Xiao 等，2023；Bavaresco 等，2024）或一致百分比（Zheng 等，2023），在 JudgeBench（Tan 等，2024）等基准上比较 LLM 输出与人工判断。挑战包括偏差（Zheng 等，2023；Li 等，2025）、判断不确定性（Wagner 等，2024）、对抗攻击脆弱性（Gu 等，2025）、特定领域的性能差距（Tseng 等，2024），以及提示词敏感性（Mizrahi 等，2024）等 LLM 生成本身已有的问题。为了提高可靠性，研究提出了基于评审团的评价方法 PoLL（Verga 等，2024），并比较微调与直接提示 GPT-4 的效果（Huang 等，2024；OpenAI 等，2024）。另一个挑战是，LLM 输出变化较大，使评审前后不一致。

LLM 判断的波动。由于 LLM 具有随机性，对相同提示词运行多次时会得到不同输出。虽然这是设计使然，但这种变化不应改变 LLM 评审对同一评估对象给出的评分。Chiang 与 Lee（2023）在 WritingPrompts 数据集（Fan 等，2018）上观察到，LLM 评审生成的评分存在一定波动。Liu 等（2023）则利用 GPT-4 的这种变化，将 temperature 设为 1，采样 20 次得到多个分数，再按这些分数的概率归一化以得到最终评分。

本文进一步分析评分高波动的影响，讨论衡量波动的指标，研究这一问题在不同任务和基准上有多普遍，并考察将 temperature 设为 0、关闭波动后能否得到更好结果。我们用自我信度或评审者内信度来描述这一问题。

自我信度。也称评审者内信度，衡量同一评审者在重复评价时，其判断是否一致；这与评审者间信度不同。常见指标包括：用于连续量表的组内相关系数 ICC（Koo 与 Li，2016；Bent 等，2014）、用于类别评分的 Cohen’s Kappa，以及可处理有序、等距或比率数据及缺失值的 Krippendorff’s Alpha（Krippendorff，2011；Wiethölter 等，2023）。

在作文评分（Cohen，2017）、物理治疗（Mischiati 等，2015）和临床诊断（Królikowska 等，2023）等领域，报告评审者内信度是常规做法。Harvey（2021）也呼吁同时考虑评审者内和评审者间信度。但 NLP 标注和 LLM 评估研究却经常省略自我信度指标（Abercrombie 等，2023a、2023b）。我们的 LLM 评审实验也确认了这一缺陷：模型与自身相比，判断并不稳定。

3 实验

我们先考虑一个简单的 NLG 评估框架：对机器生成的摘要进行二分类。事实一致性检测基准 SummaC 很适合这一目的。

随后，我们深入研究 LLM 评审在 SummEval（Fabbri 等，2021）上的表现。与 SummaC 的二分类标签不同，该基准由多个人类评审，在多个维度上按李克特量表评价摘要。

Zheng 等（2023）提出的 MT-Bench 则评估 LLM 的多轮对话与指令遵循能力。虽然它也与 NLG 有关，但与摘要相比是非常不同的任务。

3.1 数据集

SummaC。SummaC（Laban 等，2022）评估文本摘要的事实一致性，要求评审将摘要标为“与原文一致”或“与原文不一致”，见图 1。它将六个数据集统一为二分类任务：CoGenSumm（Falke 等，2019）、XSumFaith（Maynez 等，2020）、Polytope（Huang 等，2020）、FactCC（Kryscinski 等，2020）、SummEval（Fabbri 等，2021）和 FRANK（Pagnoni 等，2021）。有标准验证 / 测试划分时沿用标准划分，否则根据需要建立划分。该基准使用 Apache 2.0 许可。数据集统计见附录 C.1 的表 4。

图 1：为 SummaC 中一篇文章的摘要标注 1，即“不一致”。原文第 3 页

文章：Migaloo 因独特的体色而闻名，多年来一直是世界上唯一有记录的全白色座头鲸。人们曾在新南威尔士州海岸附近，包括度假小镇拜伦湾附近，目击它的身影。Migaloo 沿澳大利亚东海岸北上的旅程吸引了大量观鲸爱好者。这头长 14 米的哺乳动物北行时曾被发现与一位同伴同行，但现在似乎独自旅行。白鲸研究中心运营的一个 Twitter 账号会实时更新它的位置。

摘要：科学家表示，一头曾在澳大利亚海岸附近被目击的座头鲸，已在西部群岛海岸附近被捕获。

标签：1（不一致）。

SummEval。这是一个包含 1,700 个样本的摘要基准，评审依据源文档，以 1–5 分对模型生成摘要的四个维度评分：连贯性，即摘要句子之间衔接得如何；事实一致性，即摘要事实是否准确；流畅性，即每个句子的语法正确性和表达质量；相关性，即摘要是否准确抓住文章主旨，且不包含多余细节。该基准采用 MIT 许可。每个样本都有 3 位专家和 5 位众包标注者的评分。

提出这一基准的作者报告了若干一致性指标。众包标注者与第一轮专家标注的标注者间等距 Kappa 分别为 0.492 和 0.413，低于可接受范围。不过，第二轮专家标注提高了一致程度，Kappa 达到 0.7127。

图 2：对 SummEval 摘要按连贯性、事实一致性、流畅性和相关性评分，范围均为 1–5 分。原文第 3 页

文章：曼城有意签下安德莱赫特少年球员 Evangelos Patoulidis。这位 14 岁的组织核心被视为安德莱赫特青训体系中涌现的顶尖人才之一，也受到阿森纳和巴塞罗那关注。这名比利时新星在 12 岁时拒绝加入巴塞罗那拉玛西亚青训营，因为家人希望他继续学业。他持续表现出色，曼城已与安德莱赫特主席 Roger Vanden Stock 商谈，希望就补偿方案达成一致。Manuel Pellegrini 希望通过签下这位热门新秀，为球队未来作准备。

摘要：Evangelos Patoulidis 被认为是安德莱赫特青训培养出的最佳球员之一。他也受到阿森纳和巴塞罗那关注。这位比利时新星曾拒绝加入巴塞罗那拉玛西亚青训营。这位 14 岁球员吸引了从巴塞罗那到巴塞罗那的兴趣。

标注分数：连贯性 3；事实一致性 5；流畅性 4；相关性 3。

译者注：摘要最后一句本身存在重复与语义问题，以上按原文保留。

MT-Bench。在这个基准的多轮对话中，用户先向两个 LLM 提出一个问题，收到回答后再提出追问，两个模型再分别回答。人类或 LLM 评审会看到这段对话，并赋予 model_a、model_b 或 tie 标签，表示偏好模型 A、模型 B，或两者平局。图 3 展示了一个被评分的对话示例。

该基准共有 80 个问题，要求 LLM 在推理、数学等主题上开展多轮对话并遵循指令。每个问题有 30 个样本，每个样本包含问题以及模型 A、B 的回答，共 2,400 个样本。每个样本还包含 GPT-4 的判断，以及零到五位人类评审的判断。

不足两位人类评审时，无法进行人类评审之间的一致性分析。因此，我们筛出 761 个样本，每个样本至少有两份人工评分。实验所用数据中人工评分数量的分布，见附录 E.1 的表 7。

图 3：通过标注 model_a、model_b 或 tie，为 MT-Bench 中的对话判优。原文第 4 页

环节	模型 A	模型 B
用户提问	法国首都是哪里？	同左
第一轮回答	法国首都是巴黎。	巴黎是法国的首都，也是人口最多的城市。
用户追问	能简要介绍这座城市的历史吗？	同左
第二轮回答	巴黎建于公元前 3 世纪，在罗马帝国时期成为重要中心。	巴黎历史悠久，可追溯到古代。它在 10 世纪成为法国首都。

评审标签：model_b。

3.2 实验设置

三个基准都使用三种 LLM 作为评审：Llama-3.1-70B-Instruct（Grattafiori 等，2024）、DeepSeek-R1-Distill-Qwen（DeepSeek-AI 等，2025）和 Qwen3-32B（Yang 等，2025）。超参数配置与提示词模板详见附录 A。

对于三个基准，我们都让每个 LLM 评审独立运行三次，评价同一组生成结果。每次使用相同的提示词和设置，以衡量固定条件下的评审者内波动。对 SummaC，我们把测试集文章及对应的生成摘要加入提示词，交由每个模型评分。获得某个基准、某个 LLM 评审的三组分数后，使用 Krippendorff’s Alpha 计算评审者内信度。

最初实验中，我们也尝试增加运行次数，最多达到 10 次，但没有发现次数对自我信度产生显著影响，因此最终保留三次运行。

SummEval 允许分别分析连贯性、事实一致性、流畅性和相关性这些维度的信度。每次运行中，我们独立提示 LLM 评审按 1–5 分评价各维度。也就是说，三次运行中的每一次都需要四次提示，每个维度一次。由于评分是 1–5 分的李克特量表，为更符合有序评分的性质，我们计算一致性时，将 SummEval 默认的等距距离函数改成有序距离。这能把等级顺序的含义纳入计算，更合理地估计评审者内信度。

对 MT-Bench，我们基本沿用 Zheng 等（2023）的设置，并额外测量每个 LLM 评审三次运行中，评价聊天机器人回答的稳定程度。每个 LLM 评审使用与原基准相同的接口脚本，对同一批提示进行评分。

除了评审者内信度，我们还利用基准提供的专家和众包标注，分析人—人以及人—LLM 的一致性，并以 GPT-4 的判断作为 LLM—人类比较的一个参照。

各基准使用的提示词见附录。

译者注：原文此处写作“human judgments from GPT-4”，字面上混淆了人工与模型判断。根据数据集说明及表 3，上文译为“GPT-4 的判断”，并保留这一说明。文中 DeepSeek 模型使用缩写，不能据此将实验对象等同于完整版 DeepSeek-R1；所列模型名也未给出蒸馏版具体参数规模。

3.3 一致性指标

由于每个项目都有来自同一 LLM 评审的多次独立评分，我们可以将现有一致性指标改用于衡量 LLM 的自我信度。无论衡量 LLM 评审自身的信度，还是它与其他评审的一致程度，我们主要使用 Krippendorff’s Alpha。附录 B 介绍该指标及距离函数的选择。我们也用它报告不同类别评审之间的一致性，例如 LLM 与人类、专家与众包评审之间的一致性。

为什么选择 Krippendorff’s Alpha？其他 LLM 评审研究通常用不同指标计算模型与人工判断的一致性。例如，G-Eval（Liu 等，2023）使用相关性，MT-Bench（Zheng 等，2023）使用准确率。为什么我们要选择不同指标？

Artstein 与 Poesio（2008）讨论了准确率、相关性等未校正偶然一致的指标的若干缺点。虽然这些指标直观易懂，但数值不能直接跨研究比较，因为部分一致源于偶然，而偶然一致的程度会受到不同研究间变化的因素影响。其中一个因素是：类别或标签越少，偶然一致越高。例如，在标签均匀分布的二分类中，偶然一致率为 50%；若有三个标签，则为 33%。

这些指标另一个不够可靠的原因是，没有校正样本在不同类别中的分布。例如二分类中，一个标签出现的比例为 95%，那么随机情况下双方都给出这一标签的概率为 $0.95 \times 0.95 = 0.9025$，都给出另一标签的概率为 $0.05 \times 0.05 = 0.0025$。这意味着两位评审即使随机判断，预期也有 90.5% 的时候相同。观察到 90% 的一致率，看起来很高，实际上却比偶然预期还低。

Krippendorff’s Alpha 这类校正偶然一致的指标，可以解决这些缺点。与 Cohen’s Kappa（Cohen，1960）、Fleiss’ Kappa（Fleiss，1971）等其他偶然校正指标相比，它也更灵活：支持不同数量的标注者，能处理缺失数据，并可采用适合各基准评分量表的不同距离函数。基于这些原因，我们认为它适合衡量 LLM 评审的自我信度，以及模型与人工判断的一致性。

我们根据各基准评分的性质，调整 Krippendorff’s Alpha 的底层距离函数。SummaC 标签是二分类、类别型数据，因此采用名义距离：所有不一致同等处理，不假定类别有序。按照该基准原有评估设置，在比较 LLM 与人工判断时，我们也报告平衡准确率，即灵敏度与特异度的平均值，以考虑类别不平衡。

SummEval 评分是有序的，因此使用有序距离，体现不同程度的分歧，例如相差 1 分比相差 3 分的分歧小。在不同类别评审的一致性比较中，仅计算跨类别评审配对，排除同类别内部配对。

对 MT-Bench，使用两种指标：一是与原基准相同的准确率，衡量与金标准——人工多数票——的一致程度；二是采用有序距离的 Krippendorff’s Alpha，区分成对判断中不同程度的分歧，例如模型 A 更好、平局、模型 B 更好。我们同时报告评审者间一致性，例如 LLM 与人类的一致性，以及评审者内一致性，即 LLM 多次运行之间的一致性。

4 评审者内信度结果

SummaC。表 1 展示了 LLM 评审三次运行之间的 Krippendorff’s Alpha。可以看到，各模型的运行间一致性都较低，不过较新、较大的模型表现更好。Qwen 3 接近 0.8，这通常被视为良好一致性的阈值。

我们尝试将这些实验重复到五次，没有发现自我信度有显著变化。这表明，对一个模型和特定测试集来说，该数值相当稳定，不取决于运行次数。

表 1：不同 LLM 评审在 SummaC 上三次运行的自我信度，以 Krippendorff’s Alpha 衡量。

模型	自我信度
Llama 3.1	0.3263
DeepSeek-R1	0.6278
Qwen 3	0.7883

SummEval。图 4 表明，与人类评审之间的一致性相比，DeepSeek-R1 和 Qwen 3 的不同运行在连贯性和事实一致性上具有较高自我信度，但在流畅性上很低。流畅性不仅是所有 LLM 评审都信度偏低的维度，也是唯一由 Llama 表现最好的维度。这表明，LLM 评审能否稳定给分，非常依赖具体评估维度。

图 4：LLM 评审在 SummEval 上的自我信度。横轴为连贯性、事实一致性、流畅性、相关性；纵轴为 Krippendorff’s Alpha；图例为 Llama 3.1、DeepSeek-R1、Qwen 3。原文第 6 页

MT-Bench。LLM 评审在这个基准上的自我信度，比在 SummaC 和 SummEval 上低得多。Llama 3.1 三次运行的 α 为 0.265，DeepSeek-R1 为 0.507，最可靠的 Qwen 3 为 0.563。即便最好的结果，也远低于期望的 0.8。这说明，在该任务中 LLM 评分非常不稳定，甚至比摘要任务更不稳定。事实上，Qwen 3 只有在 61.3% 的样本上，三次运行都给出了相同判断。

译者注：第 3.2 节提到初步探索最多 10 次运行，本节针对 SummaC 则说最多五次。两处表述均按原文保留，不合并为同一实验次数。

5 LLM 评审能可靠地替代人类评审吗？

下一组实验研究这种自我信度不足对实际性能意味着什么。在基准中，实际性能通常指与人工标注比较的结果。SummaC 中，我们衡量 LLM 判断与人工标注的一致性；SummEval 和 MT-Bench 的每个样本则有多份人工标签，因此可以把 LLM—人类的一致程度与人—人的一致程度比较。

5.1 SummaC

图 5 报告三个 LLM 评审在 SummaC 各数据集上，相对于人工判断的平衡准确率，并列出 Laban 等（2022）提出的两种基线 SummaC_ZS 和 SummaC_CONV。每个 LLM 评审运行三次，我们先取三次判断的简单多数票，得到共识评分，再衡量其与人工标签的一致程度。

Llama 3.1 表现很差；DeepSeek-R1 能与基线竞争；Qwen 3 则在总体上明显优于基线。需要指出的是，SummaC_ZS 和 SummaC_CONV 基线针对这一任务经过微调，而本实验直接通过提示词使用现成的指令微调模型。

图 5：不同 LLM 评审在 SummaC 各数据集上，相对于人工判断的平衡准确率。横轴包含 CGS、XSF、Polytope、FactCC、SummEval、FRANK 和总体；图例为两种 SummaC 基线及三个 LLM 评审。原文第 6 页

虽然 Qwen 3 总体最好，但并非每个数据集都最好。DeepSeek-R1 在 XSumFaith 上表现最好；SummaC_CONV 在 FactCC 上最好。这并不意外，因为该基线专门使用该数据集的训练样本微调过（Laban 等，2022）。因此，LLM 能在多大程度上替代人工评审，非常依赖具体数据集，不过总体上较新、较大的模型表现更好。

表 2 显示，Llama 3.1 的准确率在不同运行之间变化较大，而 DeepSeek-R1 和 Qwen 3 相对稳定。

表 2：不同实验设置下，LLM 判断相对于人工判断的平衡准确率。

模型	单次运行：均值 ± 标准差	三次多数票	不采样
Llama 3.1	59.1 ± 2.06	61.4	58.4
DeepSeek-R1	69.8 ± 0.50	72.3	69.3
Qwen 3	79.4 ± 0.32	80.6	79.2

取多数票能改善性能吗？表 2 对每个 LLM 报告单次运行的平衡准确率、采用三次共识评分后的准确率，以及为确保每次输出相同而关闭采样后的准确率。可以看到，多数票的准确率高于单次运行的期望准确率。事实上，对 DeepSeek-R1 和 Qwen 3 来说，多数票的平衡准确率甚至高于任何单次运行达到的最高准确率。

因此，多次运行 LLM 不仅能把运行间的波动纳入考虑，还能提高相对于人工判断的准确率。这种表现也能与专门针对该任务微调的 SummaC_ZS 和 SummaC_CONV 基线竞争（Laban 等，2022）。

关闭温度采样，能在不损害性能的情况下降低波动吗？这一问题的主要原因，是这些 LLM 被设计为通过采样，对相同提示词生成略有不同的回答。因此，消除评分波动最直接的办法，就是在推理时完全不采样，以便每次得到相同输出。然而表 2 显示，不采样时模型性能会下降。这表明，自我信度与性能之间存在权衡，同时解决两者并不容易。

我们也在附录 C.2 进行了额外实验，考察少样本提示或思维链提示是否能提高信度或与人工判断的一致程度，结果没有发现这样的收益。

译者注：原文这里写“两个模型”，但表 2 实际列了三个模型，三个模型的不采样准确率都低于其单次运行均值。上文按上下文译为“模型”。这些结果来自本文指定模型和设置，不应据此推断所有任务关闭采样都会变差。关闭采样也不能脱离推理实现，直接当作所有系统绝对可复现的保证。

5.2 SummEval

图 6 展示人工标注者之间的 Krippendorff’s Alpha。专家在事实一致性上的一致程度最高，为 0.798；在流畅性上中等，为 0.588；在相关性上最低，为 0.398，说明相关性判断具有主观性。相比之下，众包标注者在各维度上的一致性普遍更低，为 0.48 - 0.51，表明其对任务的理解更有限。专家与众包标注者之间的一致性则大幅降低，最高也仅为相关性上的 0.247，凸显不同评审群体评估方式的根本差异。

图 6：SummEval 中两类人工评审各自内部及彼此之间的评审者间信度。图例为专家、众包标注者、专家—众包标注者；横轴为四个摘要质量维度；纵轴为 α 。原文第 7 页

虽然 LLM 与自身的一致性，高于人类评审彼此之间的一致性，但这并不保证模型能完全替代人工。图 7 显示，LLM 与人类专家的一致程度，会随维度、数据集和人工评审的专业程度发生很大变化。

例如，众包评分既偏离专家，也偏离 LLM，说明它们使用了相互冲突的评估标准。专家与 LLM 的一致程度略高，但仍有限，尤其是在事实一致性、连贯性等维度上；而在流畅性等主观维度上，一致性下降，甚至变成负值。

使用更大的模型，例如 Qwen 3，可以在部分维度上提高与专家的一致性。但观察到的最佳一致程度——事实一致性上的 0.726——仍低于通常接受的替代阈值。此外，不同评审类型在不同维度上的分数分布也有差异，见附录 D.1，这进一步增加了直接替代人工的难度。

图 7：SummEval 中 LLM 评审与两类人工判断之间的评审者间信度。图例包括专家—众包标注者、专家—Llama、专家—DeepSeek、专家—Qwen 3，以及众包标注者分别与三种模型的配对；横轴为四个维度，纵轴为 α 。原文第 7 页

译者注：原文称众包标注者在“各维度”上的一致性更低，但同段给出的相关性数值为：专家 0.398，众包总体范围 0.48 – 0.51，不能支持“每个维度都更低”的字面结论。以上保留原文表述和数值。

5.3 MT-Bench

人工评审之间的 Krippendorff’s Alpha 相当低，为 0.478。这与 SummEval 的结果一致：众包评审往往一致性很低。但准确率却高得多，为 0.827。这表明，用准确率描述多个评审的一致程度可能产生误导，因为它没有考虑偶然一致的概率，会使分数虚高。表 3 完整列出了各类评审与人工判断的一致程度。

表 3：不同评审相对于人类评审的一致程度。

与人类比较的评审	准确率	Krippendorff’s Alpha
人类	0.827	0.478
GPT-4	0.671	0.396
Llama 3.1	0.556	0.239
DeepSeek-R1	0.668	0.385
Qwen 3	0.719	0.426

LLM 与人类的一致性。与人类之间的比较类似，使用 Krippendorff’s Alpha 得到的一致性数值，比准确率低得多。GPT-4 在两种指标上都有较高的一致性，但仍明显低于人类之间的一致性。然而，即便人类的结果也远低于通常接受的 0.8 阈值，并且明显低于 SummEval 的一致程度，表明这项任务比摘要更难保持一致。

译者注：原文称 GPT-4 的一致性较高，但表 3 的两项指标中，Qwen 3 都高于 GPT-4。这里不替作者改写排名。α 与准确率的数值尺度和含义不同，不能把两者的数值差直接解释成某个固定比例的“虚高”。

6 讨论

6.1 主要认识

SummaC。即便只通过提示词让 LLM 为生成结果打分，也能达到与专门为该任务微调的模型相当的表现（Laban 等，2022）。但当不同运行之间波动很大时，这里的“高性能”究竟意味着什么，就值得质疑。例如，当 LLM 与自身的一致性很低时，它与人类评审达到 0.8 的一致程度，又代表什么？

我们也不知道，这种现象是否源于基准本身的局限，例如样本有噪声、任务定义不清，还是在其他基准和任务中同样广泛存在。更重要的是，被当作金标准的人工判断，是否也有与 LLM 相同的一致性问题？这些都需要进一步研究。

但 SummaC 每个样本只有一份人工判断，无法开展这样的研究，因此必须转向其他基准和任务。我们看到，LLM 评审在其中的 SummEval 数据集（Fabbri 等，2021）上尤其吃力。该数据集的每个样本在多个维度上都有多个人工判断，因此能帮助回答许多尚未解决的问题。

SummEval。LLM 评审的评审者内信度较低，不只是 SummaC 二分类标签导致的问题。它在其他指标和评分量表上依然存在。这不仅使 LLM 评审不可靠，也使不同评估框架的元评估变得困难：同一评审给出的分数会随时间波动。

这又提出一个重要问题：低评审者内信度，究竟源于 LLM 的局限，还是即便按不同维度评价，摘要任务也没有被清楚定义？可能 SummEval 中按连贯性、事实一致性等维度给摘要评分，本身就是定义不充分的任务，导致人类和 LLM 的分数都发生变化。我们需要研究其他任务的基准中是否也存在这一现象。

MT-Bench。它确认，评审者内信度的问题并不局限于摘要等单轮任务，而是广泛存在于不同基准和涉及文本生成的任务中。我们也观察到，与 Krippendorff’s Alpha 等指标相比，准确率会给出更高的一致性数值。

6.2 建议

根据这些发现，我们提出以下建议，以改善使用 LLM 及人类评审的 NLG 评估。

考虑可能存在的自我信度问题。未来研究应在评估框架中纳入评审者内信度信息，并探索在不牺牲与人工判断一致程度的前提下，提高 LLM 自我信度的方法。现有 NLG 研究已使用 Cohen’s Kappa、Krippendorff’s Alpha 等指标衡量评审者间信度，这些指标也可以改用于衡量自我信度。它们应优先于准确率等指标，因为表 3 显示，准确率没有考虑偶然一致，会使一致性数值偏高。

降低 LLM 输出的波动。第 5.1 节显示，汇总多次运行的结果，例如采用简单多数票，可以提高与人工判断的一致程度。相反，通过关闭随机变化来试图完全消除波动，会损害性能。

收集人类评审自我信度的数据。收集 NLG 任务的人工评价时，也应测量这些评价的自我信度。虽然我们发现 LLM 评审存在自我信度问题，但没有研究这一问题在人类评审中有多普遍。既然我们将人工判断视为 NLG 评估的金标准，人类评审的自我信度就可以作为一个上限，帮助判断合理期待 LLM 达到何种自我信度。

此外，也应研究培训与专业知识对自我信度的影响，因为第 5.2 节显示，专家与众包工作者给出的评分非常不同。

译者注：“人工自我信度可作为上限”是作者提出的评估参照观点；本文没有收集人类对同一材料重复评分的数据，不能据此当作已实证测得的上限。

7 结论

我们全面分析了 LLM 评审框架中的评审者内信度，揭示了这一领域评估工作的关键挑战。实验表明，即便提示词与超参数完全相同，LLM 多次评价同一内容时，自我信度仍较低。这种不一致性在多种任务和指标上持续存在。虽然 Qwen 3 等较新、较大的模型，比 Llama 3.1 等模型更一致，但仍经常达不到标准信度阈值。

本研究也存在一些潜在风险。我们通过模型与人工判断的一致程度衡量 LLM 评审性能，而人工标签本身可能因标注者间一致程度不足而带有噪声。LLM 判断也可能偏好特定语言风格，从而影响本文报告的分数。

尽管如此，这些发现对 LLM 评审研究仍有重要意义。只报告单次 LLM 判断而不提供一致性指标，可能产生误导。流畅性等文本质量方面，无论对人还是机器，都仍难以可靠评价。此外，专家与众包评审之间明显的分歧，也说明必须明确：LLM 究竟应模拟哪一类人类偏好。

虽然 LLM 评审具有可扩展性，但仍面临严重的可靠性挑战。要构建能够有意义地区分文本质量的评估框架，就必须解决这些问题。

局限性

近期研究分析了 LLM 评审的推理轨迹（Wang 等，2023），考察这些轨迹是否有用，以及监督微调或强化学习如何影响其性能（Chen 等，2025）。虽然本实验使用了 DeepSeek-R1 和 Qwen 3 等推理模型，但我们没有探索推理轨迹与自我信度之间的关系。

另外，尽管通过提示词使用 LLM 评审，在 SummaC 等基准上与人工判断的一致程度能超过基线，但我们没有研究微调能否进一步提高性能，因为这超出本文范围。除了微调，还有其他值得探索的方向，例如提示词结构如何影响信度；或者探查模型内部，研究某一特定层是否导致不同运行给出相互冲突的分数。

最后，虽然我们指出摘要或多轮对话评估的主观性，可能加剧 LLM 的自我信度问题，但尚未通过与其他更客观任务的自我信度比较，来量化这种主观性。尽管如此，本研究揭示了生成任务评估中的一个重要问题，并讨论了能够使评估更稳健的实验方法和数据收集原则。

我们还将模型选择限定为开放权重模型，以便在本地运行实验，并完整访问模型权重。然而，GPT-5（OpenAI，2025）和 Claude 4（Anthropic，2025）等专有模型，在推理和智能体基准上已有很大进展。除了上述未来方向，比较这些模型与本文模型的自我信度，也能进一步理解这一现象的普遍程度。

致谢

本研究使用了 Delta 高级计算与数据资源。该资源由美国国家科学基金会（项目编号 OAC 2005572）和伊利诺伊州支持，是伊利诺伊大学厄巴纳—香槟分校及其国家超级计算应用中心的合作项目。

附录 A 实验设置的更多细节

对于全部三个基准及三个 LLM，我们均使用一台配有 4 块 A100 GPU 的服务器，以及 transformers 库（Wolf 等，2020）运行实验。除非另作说明，使用各模型推荐的默认参数。这意味着，Llama 3.1 和 DeepSeek-R1 的 temperature 为 0.6、top_p 为 0.9；Qwen 3 的 temperature 为 0.6、top_p 为 0.95。

对于 SummaC，我们使用下面的提示词获得二分类标签，表示摘要与原文一致或不一致。图 8 展示了该基准每次运行的提示词。

图 8：SummaC 每次运行使用的提示词

```
任务：对照源文档，分析摘要是否存在事实不一致。不一致可能包括：
1. 幻觉：加入源文档中不存在的信息。
2. 矛盾：陈述与源文档内容相反。
3. 实体错误：姓名、角色或地点不正确。
4. 遗漏：摘要缺少关键要点。
5. 时间错误：事件顺序或时间范围不正确。

输出：只输出一个数字。0 表示摘要一致，1 表示摘要不一致。
文档：{{Full source text}}
摘要：{{Generated Summary}}
```

对于 SummEval，共有连贯性、事实一致性、流畅性和相关性四个维度。每次运行时，我们独立提示 LLM 评审四次，每个维度一次。提示词见图 9。

图 9：按四个维度评估 SummEval 生成摘要的提示词

（a）连贯性。

```
说明：你将看到一篇新闻文章的摘要。
你的任务是按一个维度对摘要评分。

评估标准：连贯性（1–5 分），即摘要的结构和逻辑组织是否良好。

评估步骤：
1. 阅读文章并识别关键要点。
2. 检查摘要是否清晰、合乎逻辑地呈现这些要点。
3. 给出 1–5 分。

示例：
新闻文章：
{{Source Text}}
摘要：
{{Summary}}

评分表（只输出分数）：
连贯性：
```

（b）事实一致性。

```
说明：你将看到一篇新闻文章的摘要。
你的任务是按一个维度对摘要评分。

评估标准：事实一致性（1–5 分）。摘要不应与原文矛盾；
应对虚构事实扣分。

评估步骤：
1. 阅读文章和摘要。
```

2. 识别所有事实错误。
3. 给出 1–5 分。

示例：
新闻文章：
{{Source Text}}
摘要：
{{Summary}}

评分表（只输出分数）：
事实一致性：

（c）流畅性。

说明：你将看到一篇新闻文章的摘要。
你的任务是按一个维度对摘要评分。

评估标准：流畅性（1–5 分），包括语法、拼写、标点、用词和句子结构。

评估步骤：
1. 阅读摘要。
2. 识别影响可读性的语言问题。
3. 给出 1–5 分。

示例：
摘要：
{{Summary}}

评分表（只输出分数）：
流畅性：

（d）相关性。

说明：你将看到一篇新闻文章的摘要。
你的任务是按一个维度对摘要评分。

评估标准：相关性（1–5 分）。只包含原文的重要信息；应对冗余扣分。

评估步骤：
1. 阅读摘要和文章。
2. 评估对关键要点的覆盖情况。
3. 给出 1–5 分。

示例：
新闻文章：
{{Source Text}}
摘要：
{{Summary}}

评分表（只输出分数）：
相关性：

对于 MT-Bench，我们使用单个提示词，要求 LLM 评审在两个生成结果之间作出选择；如果无法选出明确优胜者，则标为 tie。样本分为 math 和 general 两类。区别在于，math 对话还包含用户问题的参考答案。图 10 是数学类样本提示词，图 11 是一般类样本提示词。

图 10：评价 MT-Bench 数学类问题两个生成回答的提示词

```
请担任公正的评审，评价两个 AI 助手对用户问题所给回答的质量。
评估应考虑正确性和帮助程度。

你将获得参考答案、助手 A 的回答及助手 B 的回答。
你的任务是判断，哪个助手对用户的第二个问题给出了正确且有帮助的回答。
请先将两个助手的回答与参考答案比较，找出并纠正错误。
避免位置偏差，确保回答的呈现顺序不影响判断。
不要让回答长度影响评价。不要偏爱助手的某些名称。
尽可能客观。

给出解释后，严格按以下格式输出最终裁决：
助手 A 更好，输出 "[[A]]"；助手 B 更好，输出 "[[B]]"；
平局则输出 "[[C]]"。

<|参考答案开始|>
用户：
{{question_1}}
参考答案：
{{ref_answer_1}}
用户：
{{question_2}}
参考答案：
{{ref_answer_2}}
<|参考答案结束|>

<|助手 A 与用户的对话开始|>
用户：
{{question_1}}
助手 A：
{{answer_a_1}}
用户：
{{question_2}}
助手 A：
{{answer_a_2}}
<|助手 A 与用户的对话结束|>

<|助手 B 与用户的对话开始|>
用户：
{{question_1}}
助手 B：
{{answer_b_1}}
用户：
{{question_2}}
助手 B：
{{answer_b_2}}
```

<|助手 B 与用户的对话结束|>

图 11：评价 MT-Bench 一般类问题两个生成回答的提示词

请担任公正的评审，评价两个 AI 助手对用户问题所给回答的质量。
应选择更好地遵循用户指令、回答用户问题的助手。
评价应考虑帮助程度、相关性、准确性、深度、创造性及细节程度等因素。
重点关注谁对用户的第二个问题回答得更好。

请先比较两个助手的回答，并给出简短解释。
避免位置偏差，确保回答的呈现顺序不影响判断。
不要让回答长度影响评价。不要偏爱助手的某些名称。
尽可能客观。

给出解释后，严格按以下格式输出最终裁决：
助手 A 更好，输出 "[[A]]"；助手 B 更好，输出 "[[B]]"；
平局则输出 "[[C]]"。

<|助手 A 与用户的对话开始|>
用户：
{{question_1}}
助手 A：
{{answer_a_1}}
用户：
{{question_2}}
助手 A：
{{answer_a_2}}
<|助手 A 与用户的对话结束|>

<|助手 B 与用户的对话开始|>
用户：
{{question_1}}
助手 B：
{{answer_b_1}}
用户：
{{question_2}}
助手 B：
{{answer_b_2}}
<|助手 B 与用户的对话结束|>

译者注：上述模板中的提示语及对话边界文字已译成中文；变量占位符和 [[A]] 等输出标签保留原样。这是阅读译本，不是经过等价性验证的中文实验提示词；直接替换原始英文提示词可能改变模型行为。

附录 B 一致性指标：Krippendorff’s Alpha

Krippendorff’s Alpha（α）是一种校正偶然一致的信度系数，用于量化两个或更多编码者——观察者、评分者——对一组项目赋值时的一致程度。换句话说，它衡量多个标注者对相同项目的编码有多一致。

Klaus Krippendorff 在内容分析领域提出 α。它推广了 Cohen’s Kappa（Cohen，1960）、Fleiss’ Kappa（Fleiss，1971）等许多经典一致性统计量，可适用于任意数量的编码者、类别或量表取值，以及名义、有序、等距、比率等不同测量层级。

α 可以容纳任意数量的评审者，只需至少两位；也能适应从名义类别到等距或比率量表的不同测量层级。它可以处理缺失数据，在统计成对判断时略去缺失项；即便样本量不同或类别很多，也能得到可比较的信度系数。这种灵活性，使其适用于多于两位评审的情况，以及需要考虑部分一致的有序类别。总体而言，它因适用范围广、对偶然一致的处理有统计依据，而适合多种评分和标注任务。

B.1 数学记号

Krippendorff’s Alpha 的一般形式为：

$$\alpha = 1 - \frac{D_o}{D_e} \tag{1}$$

其中，$D_o = \sum \delta(v_i, v_j)$，表示对每个项目中不同评审取值 v_i, v_j 的成对距离求和。

分母 D_e 则对所有可能的取值配对计算距离，并按各值的频率加权，相当于把赋值在评审之间随机置换。也就是说，给定观察到的类别分布，D_e 表示仅由偶然因素造成的平均预期分歧。

这种预期分歧，是 Krippendorff’s Alpha 区别于相关性或一致百分比等指标的关键：它考虑偶然一致，避免夸大一致性。为理解 D_e 的计算，设：

1. V 为编码者可以给出的全部取值集合，例如五分量表中 V={1,2,3,4,5}。

2. n_v 为取值 $v \in V$ 在所有项目与编码者中出现的次数。

3. $N=\sum_{v \in V} n_v$，即赋值总次数。

由此得到相对频率，也就是概率：

$$p_v = \frac{n_v}{N} \tag{2}$$

现在，对所有取值的无序配对 $(v,v') \in V \times V$ 求和，按编码者独立赋值时，各配对偶然共同出现的频率加权，以计算预期分歧。加权项定义如下：

- 若 $v \neq v'$，随机抽到这一配对的概率为 $2p_v p_{v'}$。系数 2 将 (v,v’) 与 (v’,v) 两种顺序都计入同一个无序配对。
- 若 $v=v'$，抽到 (v,v) 的概率为 p_v^2。

采用距离函数 $\delta(v,v')$，预期分歧为：

$$D_e = \sum_{v \in V} \sum_{v' \in V} p_v p_{v'} \, \delta(v, v') \tag{3}$$

从概念上看，它就是从整体分布中随机选取两个值时，分歧的期望值。

观察者完全一致时，$D_o=0$、$\alpha=1$，表示完全可靠。观察者之间只有偶然一致时，$D_o=D_e$、$\alpha=0$，表示没有信度。

译者注：上述是原文给出的简化说明。原文在部分公式中把 D_o 写成距离之和，在式（8）中又写成平均距离；式（3）则使用概率加权的期望距离。不能将不同归一化尺度直接混用来实现 α。需要计算指标时，应采用明确定义了权重、缺失值和有限样本处理方式的统一实现。另外，原文在 B.1 用 N 表示赋值总数，B.2.2 又用它表示项目数，以下按各处含义保留。

B.2 距离函数

α 的关键组成部分，是衡量两个编码取值分歧程度的距离函数 $\delta(v,v')$。距离函数的选择反映数据的测量层级，也从根本上影响分歧的计算。一般来说，两位评审一致时距离必须为 0；不一致时距离大于 0。名义、有序、等距数据各有不同的常见距离函数。距离选择会改变 D_o 和 D_e 如何累计分歧。

B.2.1 名义距离

对于没有内在顺序的名义型、类别型数据，标准距离函数是离散的二值度量。在这种情况下，任意两个不同类别都被视为完全不同：

$$\delta_{\text{nominal}}(v,v') = \begin{cases} 0, & v = v' \\ 1, & v \neq v' \end{cases} \tag{4}$$

因此，完全匹配的距离为 0，任何不匹配的距离都为 1。使用这一距离时，观察分歧 D_o 实质上就是不同评审之间所有成对编码不一致的计数，或加权计数。

名义距离下的 D_o 为：

$$D_o = \sum_{\text{pairs}} \delta_{\text{nominal}}(v_i, v_j) \tag{5}$$

所以，D_o 本质上是不匹配的次数。

名义距离适用于取值只是标签或类别的情况，例如颜色名、物体类别，以及“是 / 否”“红 / 绿 / 蓝”等编码类别。这里不区分两个类别“差得有多远”，只判断它们是否不同。

实际上，采用名义距离的 α，类似于对精确一致比例进行偶然校正，在思路上与 Kappa 相近。所有分歧权重相同，因此轻微编码错误，如“猫”与“狗”，和严重错误，如“猫”与“汽车”，对 D_o 的贡献相同。由于 SummaC 的项目是二分类标签，我们使用这一距离。

B.2.2 有序距离

对于有序数据，即有等级的类别，例如“低 / 中 / 高”调查回答或李克特量表，距离函数必须体现取值顺序。常见做法是使用等级差的平方，或基于等级累计频数的公式。Krippendorff 最初定义的有序距离为：

$$\delta_{\text{ordinal}}(v,v') = \left(\sum_{g=\min(v,v')}^{\max(v,v')} n_g \quad \frac{n_v + n_{v'}}{2} \right)^2 \tag{6}$$

其中，n_v 为类别 v 的频数。简单来说，它通常体现两个取值等级位置差的平方，并可能按类别频数进行标准化。关键效果是：类别的等级相距越远，有序距离越大。

对于有序距离，若有 N 个被编码项目，第 j 个项目由 m_j 位编码者给出 $v_{1j},\cdots,v_{m_j j}$，编码者配对总数为：

$$n = \sum_{j=1}^{N} \binom{m_j}{2} \tag{7}$$

采用有序距离 δ_{ord}，D_o 可写为：

$$D_o = \frac{1}{n} \sum_{j=1}^{N} \sum_{i<i'} \delta_{ord}(v_{ij}, v_{i'j}) \tag{8}$$

内层求和遍历项目 j 中全部 $C(m_j,2)$ 个不同编码者配对 (i,i')。等价地，它是项目内分歧的加权平均。换句话说，D_o 是同一项目中评分配对的所有有序平方距离的平均值。

每个类别都有等级，例如 1、2、3 等。类别 c 和 k 的标准有序平方距离，由它们在观察数据分布中的等级间隔决定：

$$\delta_{ord}(c,k) = \left(\sum_{g=\min(c,k)}^{\max(c,k)} n_g \quad - \frac{n_c + n_k}{2} \right)^2 \tag{9}$$

其中，n_g 为合并数据中类别 g 的频数。直观地说，它统计 c 和 k 之间的样本数，加上两个端点各一半的频数，再将这个间隔平方。代入 D_o 后，每对评分都贡献一个相应类别等级间隔的平方。

有序距离适用于类别有顺序、但不一定等间隔的情形，例如“好、更好、最好”，或“非常同意、同意、中立、不同意、非常不同意”。在 α 中使用这一距离，意味着两位评审给出相邻等级，如五分量表中的 2 与 3，所产生的分歧，小于给出两端等级，如 1 与 5。

从公式上看，D_o 会累计每个配对的等级差平方，因此 α 对较大的等级分歧惩罚更重。在实践中，原文认为这通常比名义距离产生更大的 D_o，从而使 α 更小，因为它编码了评审“如何不同”，而不只是“是否不同”。也可以把有序距离标准化到 0–1，但对 α 来说，关键是相对权重。

我们在 SummEval 和 MT-Bench 中使用这一距离。前者使用李克特量表；后者有 model_a、model_b、tie 三个标签，使我们可以区分“模型 A 与平局”的分歧，以及“模型 A 与模型 B”的分歧。

译者注：这里保留了原文关于“较大 D_o 导致较小 α”的解释。但改变距离函数也会改变 D_e，因此不能仅根据 D_o 的大小，断言不同距离下 α 必然如何变化。有序距离公式依赖类别频数，也不应无条件等同于直接将标签数字之差平方。

B.2.3 等距距离

对于等距数据，即相邻刻度间隔相同的定量取值，通常采用差值的平方：

$$\delta_{interval}(v,v') = (v \quad v')^2 \tag{10}$$

这种方法把数值视为实数轴上的点，衡量两点之间的平方距离。

采用等距距离时，D_o 为：

$$D_o = \sum_{\text{pairs}} (v_i \quad v_j)^2 \tag{11}$$

因此，D_o 是所有编码者配对之间的平方差总和。

等距距离适用于等距量表，例如摄氏温度，或其他差值有意义的数值评分。例如，两位评审给同一项目打 3.0 和 4.5 分，则距离为 $(3.0-4.5)^2=2.25$。在 α 的计算中，每个成对差值都会贡献到总分歧。平方形式使 α 类似于基于方差的一致性度量：数值差异越大，D_o 越大。

也就是说，等距距离使 α 对分歧的幅度敏感。相差 1 个单位的两位编码者，与相差 5 个单位的两位编码者，对 D_o 的贡献会很不相同。数值差异具有实质意义时，这种做法是合适的。本文没有使用这一距离，因为我们研究的数据集没有这类数值标签；为使解释完整，仍在这里介绍。

译者注：SummEval 虽然显示为 1–5 的数字，本文仍将它们视为有序等级，未假定相邻分值具有相同间隔。因此，“没有这类数值标签”应结合测量层级理解，不是说数据中完全没有数字。

附录 C SummaC 基准的更多细节

C.1 SummaC 基准的数据集统计

表 4 列出 SummaC 中六个数据集各自的测试样本数。

表 4：SummaC 各数据集的测试样本数。

数据集	测试样本数
CoGenSumm（Falke 等，2019）	400
XSumFaith（Maynez 等，2020）	1,250
Polytope（Huang 等，2020）	634
FactCC（Kryscinski 等，2020）	503
SummEval（Fabbri 等，2021）	850
FRANK（Pagnoni 等，2021）	1,575

C.2 思维链与少样本提示对 SummaC 评审者内信度及准确率的影响

语言模型使用上的两个突破，是少样本提示（Brown 等，2020）和思维链提示（CoT；Wei 等，2022）。少样本提示通过向模型提供少量带标签的示例，展示如何更准确地完成目标任务。思维链提示则让模型生成通向答案的中间推理步骤。它们代表上下文学习的不同方面，可以组合，也可以独立使用。

接下来的实验研究这些技术能否解决自我信度问题。在少样本设置中，我们在提示词内加入 5 个正例和 5 个负例。在思维链设置中，要求模型先逐步思考再回答。在“两者同时”设置中，同时使用少样本和思维链提示。

表 5：默认设置，以及分别或同时使用少样本、思维链提示时，LLM 评审在 SummaC 上的自我信度。

设置	Llama 3.1	DeepSeek-R1	Qwen 3
默认	0.3263	0.6278	0.7883
加少样本提示	0.3245	0.6166	0.7804
加思维链提示	0.3219	0.6132	0.7796
两者同时	0.3206	0.6134	0.7801

表 5 使用三次运行之间的 Krippendorff’s Alpha 衡量自我信度。少样本提示没有明显改变模型自我信度，反而使一致性略有下降。这种变化并不显著，表明不能轻易通过不同提示策略解决自我信度问题。

表 6：默认设置，以及分别或同时使用少样本、思维链提示时，LLM 多数票判断相对于人工判断的平衡准确率。

设置	Llama 3.1	DeepSeek-R1	Qwen 3
默认	61.4	72.3	80.6
加少样本提示	62.9	72.8	80.6
加思维链提示	60.8	71.6	80.4
两者同时	60.1	72.1	80.3

表 6 展示模型相对于人工判断的准确率。虽然少样本提示让 Llama 3.1 和 DeepSeek-R1 略有改善，但两种提示策略都没有带来显著性能跃升。

可能的原因是，已有观察指出，少样本提示并不总能很好地适用于 DeepSeek-R1、Qwen 3 和 o1 等推理模型（DeepSeek-AI 等，2025；Nori 等，2024）。而思维链提示也不一定提高推理模型准确率，因为模型已经隐式执行思维链推理（Eliot，2025）。有趣的是，Qwen 3 在这些新设置中的变化最小，说明较新的推理模型对不同提示词相当稳健。

译者注：本节的“不显著”“稳健”等措辞按原文翻译；这些表格本身未提供显著性检验结果或置信区间，不能把作者措辞扩展为额外统计证据。

附录 D SummEval 评审者间一致性的补充分析

D.1 SummEval 中不同评审群体的评分分布

图 12 展示不同评审类型在 SummEval 四个维度上的分数分布。众包标注者的分布在不同维度上没有明显变化，说明缺少适当专业知识的人类评审，不擅长区分不同评估维度。

其余四类评审能够区分不同维度，但对同一个维度给出的分数分布也各不相同。虽然 DeepSeek-R1 和 Qwen 3 比 Llama 3.1、众包标注者更符合专家判断，但它们的分布依然非常不同。这意味着，每类评审对一个维度都有自己的内部定义，从而严格限制了它们可能达到的一致程度。

图 12：SummEval 中，不同评审在全部评估维度上给出的分数分布。五组图分别对应专家、众包标注者、Llama 3.1、DeepSeek-R1、Qwen 3；每组都包含连贯性、事实一致性、流畅性、相关性的 1–5 分分布。原文第 19 页

附录 E MT-Bench 基准的补充细节

E.1 MT-Bench 样本构成

表 7：MT-Bench 中，分别具有 2、3、4、5 份人工判断的样本数。

每个样本的人工判断数	2	3	4	5
样本数	599	132	24	6

表 7 展示 MT-Bench 中具有 2、3、4 或 5 份人工判断的样本数量。它们就是本实验使用的样本，因为我们过滤掉了仅有一份人工判断的样本。

参考文献：中文题名与检索信息

以下依原文顺序列出。完整作者名单、出版信息与参考链接见原文参考文献，第 9–12 页。这里翻译题名，保留作者—年份标识，便于与正文对应。

作者—年份	中文题名	原文检索信息
Abercrombie、Hovy 与 Prabhakaran，2023a	时间与第二语言对仇恨言论标注中标注者内一致性及稳定性的影响	LAW-XVII，96–103
Abercrombie、Rieser 与 Hovy，2023b	一致性是关键：利用标注者内一致性分解 NLP 中的标签变化	arXiv:2301.10684
Anthropic，2025	Claude 4 介绍：Claude Opus 4 与 Claude Sonnet 4	anthropic.com/news/claude-4；原文访问日期 2025-09-19
Artstein 与 Poesio，2008	综述：计算语言学中的编码者间一致性	Computational Linguistics 34(4)，555–596
Ashktorab 等，2024	对齐人类与 LLM 的判断：EvalAssist 对特定任务评估及 AI 辅助评价策略偏好的启示	arXiv:2410.00873
Banerjee 与 Lavie，2005	METEOR：与人工判断具有更高相关性的机器翻译自动评估指标	ACL 机器翻译 / 摘要内在与外在评估指标研讨会，65–72
Bavaresco 等，2024	用 LLM 替代人类评审？覆盖 20 项 NLP 评估任务的大规模实证研究	arXiv:2406.18403

作者—年份	中文题名	原文检索信息
Bent 等，2014	健康参与者前内侧伸展测试的评审者内与评审者间信度	Open Access Journal of Sports Medicine 5，1–10
Brown 等，2020	语言模型是少样本学习器	NeurIPS 2020
Celikyilmaz、Clark 与 Gao，2021	文本生成评估综述	arXiv:2006.14799
Chen 等，2025	JudgeLRM：以大型推理模型为评审	arXiv:2504.00050
Chiang 与 Lee，2023	大语言模型能替代人工评估吗？	ACL 2023 长论文卷，15607–15631
Chiang 等，2024	Chatbot Arena：通过人类偏好评估 LLM 的开放平台	arXiv:2403.04132
Jacob Cohen，1960	名义量表的一致性系数	Educational and Psychological Measurement 20(1)，37–46
Yoav Cohen，2017	估计作文评分者的评审者内信度	Frontiers in Education 2
DeepSeek-AI 等，2025	DeepSeek-R1：通过强化学习激发 LLM 的推理能力	arXiv:2501.12948
Eliot，2025	为什么对推理型 LLM 使用思维链提示反而会碍事	原文仅列作者、年份及题名
Fabbri 等，2021	SummEval：重新评估摘要评估	arXiv:2007.12626
Falke 等，2019	按正确性为生成摘要排序：自然语言推断一个有趣但困难的应用	ACL 2019，2214–2220
Fan、Lewis 与 Dauphin，2018	分层神经故事生成	ACL 2018 长论文卷，889–898
Fleiss，1971	衡量多位评审的名义量表一致性	Psychological Bulletin 76
Grattafiori 等，2024	Llama 3 模型家族	arXiv:2407.21783
Gu 等，2025	LLM 评审综述	arXiv:2411.15594
Harvey，2021	动物行为研究中评审者间、评审者内及重测信度简明指南	原文仅列作者、年份及题名
Dandan Huang 等，2020	我们在文本摘要上取得了什么进展？	EMNLP 2020，446–469

作者—年份	中文题名	原文检索信息
Hui Huang 等，2024	LLM 评审用于模型评估的实证研究：微调评审模型不能普遍替代 GPT-4	arXiv:2403.02839
Koo 与 Li，2016	信度研究中组内相关系数的选择与报告指南	Journal of Chiropractic Medicine 15(2)，155–163；原文另列 2017 年勘误
Krippendorff，2011	计算 Krippendorff’s Alpha 信度	Computing Krippendorff’s Alpha-Reliability
Kryscinski 等，2020	评估抽象式文本摘要的事实一致性	EMNLP 2020，9332–9346
Królikowska 等，2023	提高骨科与运动医学测量的信度	Knee Surgery, Sports Traumatology, Arthroscopy 31(12)，5277–5285
Laban 等，2022	SummaC：重新审视基于 NLI 的摘要不一致检测模型	TACL 10，163–177
Dawei Li 等，2025	从生成到判断：LLM 评审的机遇与挑战	arXiv:2411.16594
Haitao Li 等，2024	以 LLM 为评审：基于 LLM 的评估方法全面综述	arXiv:2412.05579
Lin，2004	ROUGE：用于摘要自动评估的软件包	Text Summarization Branches Out，74–81
Liu 等，2023	G-Eval：使用 GPT-4 进行更符合人工判断的 NLG 评估	EMNLP 2023，2511–2522
Maynez 等，2020	关于抽象式摘要的忠实性与事实性	ACL 2020，1906–1919
Mischiati 等，2015	运动障碍筛查的评审者内与评审者间信度：Foundation Matrix 运动控制测试	Journal of Sports Science and Medicine 14(2)，427–440
Mizrahi 等，2024	到底是什么“先进水平”？呼吁用多提示词评估 LLM	TACL 12，933–949
Nori 等，2024	从 Medprompt 到 o1：探索医学挑战问题及其他任务的运行时策略	From Medprompt to o1: Exploration of Run-Time Strategies for Medical Challenge Problems and Beyond
OpenAI，2025	GPT-5 介绍	openai.com/index/introducing-gpt-5/；原文访问日期 2025-09-19
OpenAI 等，2024	GPT-4 技术报告	arXiv:2303.08774

作者—年份	中文题名	原文检索信息
Pagnoni、Balachandran 与 Tsvetkov，2021	通过 FRANK 理解抽象式摘要的事实性：事实性指标评测基准	NAACL 2021，4812–4829
Papineni 等，2002	BLEU：机器翻译自动评估方法	ACL 2002，311–318
Sellam、Das 与 Parikh，2020	BLEURT：学习稳健的文本生成评估指标	ACL 2020，7881–7892
Singh 等，2025	排行榜幻象	arXiv:2504.20879
Tan 等，2024	JudgeBench：评估基于 LLM 的评审的基准	arXiv:2410.12784
Thakur 等，2025a	评审评审者：评估 LLM 评审的对齐程度与脆弱性	arXiv:2406.12624
Thakur 等，2025b	评审评审者：评估 LLM 评审的对齐程度与脆弱性	第四届 Generation, Evaluation and Metrics 研讨会，404–430
Thomson、Reiter 与 Belz，2024	NLP 人工评估实验中的常见缺陷	Computational Linguistics 50(2)，795–805
Tseng 等，2024	专家级语言模型也是专家级标注者吗？	arXiv:2410.03254
Verga 等，2024	用评审团替代单一评审：以多样化模型组成的评审团评价 LLM 生成结果	arXiv:2404.18796
Wagner 等，2024	LLM 评审的黑箱不确定性量化方法	arXiv:2410.11594
Wang 等，2023	自一致性提高语言模型的思维链推理能力	arXiv:2203.11171
Wei 等，2022	思维链提示激发大语言模型的推理能力	NeurIPS 2022
Wiethölter 等，2023	肩关节假体周围骨折现有分类系统的观察者间与观察者内信度评估	Journal of Clinical Medicine 12(9)，3168
Wolf 等，2020	Hugging Face Transformers：先进的自然语言处理	arXiv:1910.03771
Xiao 等，2023	评估评估指标：利用测量理论分析 NLG 评估指标的框架	EMNLP 2023，10967–10982
Yang 等，2025	Qwen3 技术报告	arXiv:2505.09388
Zhang 等，2020	BERTScore：用 BERT 评估文本生成	ICLR 2020
Zheng 等，2023	通过 MT-Bench 与 Chatbot Arena 评估 LLM 评审	arXiv:2306.05685

译文制作日期：2026 年 10 月 27 日。本文仅翻译和核对论文，不构成对当前项目实验的独立复核，也没有据此追加实验调用。